



中国科学技术大学

UNIVERSITY OF SCIENCE AND TECHNOLOGY OF CHINA

信号统计分析

第6章 波形估计



本章内容

- 6.1 波形估计的分类
- 6.2 连续信号的维纳滤波
- 6.3 离散维纳滤波
- 6.4 $\alpha - \beta$ 滤波
- 6.5 卡尔曼滤波




6.1 波形估计的分类

假设观测信号为 $x(t) = s(t) + n(t)$ ，待估计信号为
 $g(t) = s(t + \alpha)$ ，当前时刻为 t_0

滤波：估计信号 $s(t_0)$

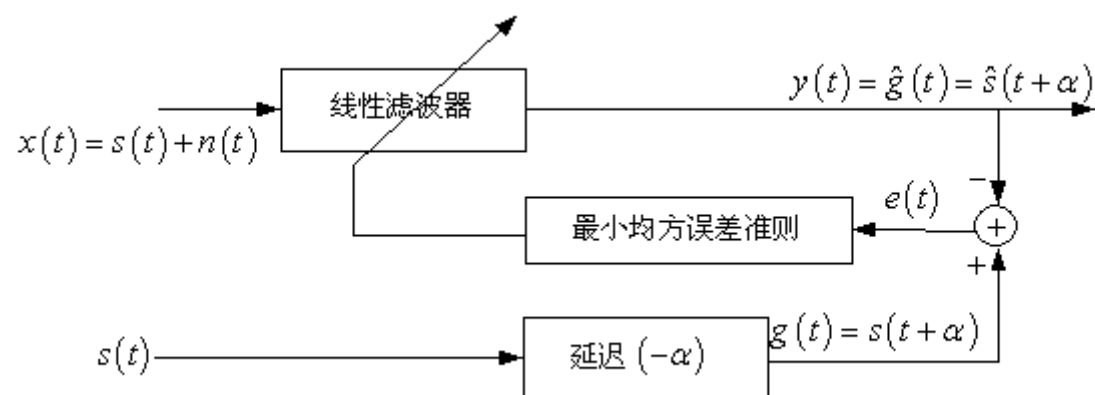
预测：估计信号 $s(t_0 + \alpha)$ $\alpha > 0$

平滑：估计信号 $s(t_0 + \alpha)$ $\alpha < 0$

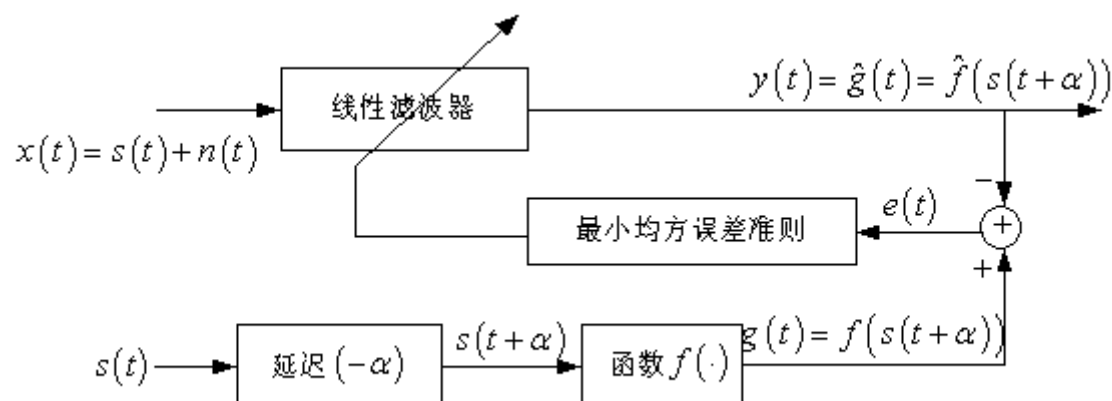




波形估计目的：选取线性滤波器的冲激响应函数或传输函数，使估计的均方误差达到最小。



拓展：





6.2 连续信号的维纳滤波

基本思想：

寻找线性滤波器的最佳冲激响应或传输函数，使滤波器的输出波形作为输入信号波形的最佳估计，即使波形估计的均方误差达到最小。

主要内容：

- 6.2.1. 广义平稳随机信号的维纳滤波原理
- 6.2.2. 物理不可实现维纳滤波器的解
- 6.2.3. 物理可实现维纳滤波器的解
- 6.2.4. 最小均方误差



6.2.1 广义平稳随机信号的维纳滤波原理

假设信号和噪声均为零均值的广义平稳随机过程且互不相关，则观测信号 $x(t) = s(t) + n(t)$ 也是零均值广义平稳随机过程，且和 $g(t)$ 联合广义平稳。

线性滤波器的冲激响应为 $h(t)$ ，输出信号 $y(t)$ 为：

$$y(t) = \int_{-\infty}^{+\infty} h(t-\tau) x(\tau) d\tau = \int_{-\infty}^{+\infty} h(\tau) x(t-\tau) d\tau$$

估计误差为： $e(t) = g(t) - \hat{g}(t) = g(t) - y(t)$

均方误差为： $E\{e^2(t)\} = E\{[g(t) - y(t)]^2\} \rightarrow \min$



利用线性最小均方误差估计的正交条件

$$E\{e(t)x(\tau')\} = 0, \quad -\infty < \tau' < +\infty$$

可得非因果广义平稳随机过程的维纳-霍夫方程

$$R_{gx}(\eta) = \int_{-\infty}^{+\infty} h(\lambda) R_x(\eta - \lambda) d\lambda, \quad -\infty < \eta < +\infty$$

因果广义平稳随机过程的维纳-霍夫方程

$$R_{gx}(\eta) = \int_0^{+\infty} h(\lambda) R_x(\eta - \lambda) d\lambda \quad 0 \leq \eta < +\infty$$



6.2.2 物理不可实现维纳滤波器的解

由非因果维纳-霍夫方程，可得

$$S_{gx}(\omega) = H(j\omega)S_x(\omega)$$

即

$$H(j\omega) = \frac{S_{gx}(\omega)}{S_x(\omega)}$$

对于 $g(t) = s(t + \alpha)$ ，有


$$H(j\omega) = \frac{S_s(\omega)e^{j\omega\alpha}}{S_s(\omega) + S_n(\omega)}$$



维纳滤波器的幅频相应为

$$|H(j\omega)| = \frac{|S_s(\omega)/S_n(\omega)|}{|S_s(\omega)/S_n(\omega) + 1|} \triangleq \frac{1}{|1 + 1/SNR(\omega)|}$$

其中 $SNR(\omega) = S_s(\omega) / S_n(\omega)$ 。



此时估计的最小均方误差为：

$$E\{e^2(t)\}_{\min} = R_g(0) - \int_{-\infty}^{+\infty} h(\lambda) R_{gx}(\lambda) d\lambda$$



例 6.1

考虑输入信号 $x(t)$ 为高斯-马尔可夫信号 $s(t)$ 和噪声 $n(t)$ 的叠加，假定信号和噪声统计独立，其功率谱分别为 $S_s(\omega) = \frac{3}{1+\omega^2}$ 和 $S_n(\omega) = 1$ 。

求： α 分别取0，+1和-1时物理不可实现维纳滤波器的冲激响应及最小均方误差。



6.2.3 物理可实现维纳滤波器的解

对于因果的维纳-霍夫方程：

$$R_{gx}(\eta) = \int_{-\infty}^{+\infty} h(\lambda) R_x(\eta - \lambda) d\lambda \quad 0 \leq \eta < +\infty$$

其求解方法有如下两种：

1. 频谱因式分解法
2. 预白化法



1. 频谱因式分解法

$$\text{引入一个新函数: } b(\eta) = \begin{cases} 0 & \eta \geq 0 \\ \text{形式不作具体规定} & \eta < 0 \end{cases}$$

则有:

$$R_{gx}(\eta) + b(\eta) = \int_{-\infty}^{+\infty} h(\lambda) R_x(\eta - \lambda) d\lambda \quad -\infty < \eta < +\infty$$

拉氏变换后得:

$$S_{gx}(s) + B(s) = H(s) S_x(s)$$

可知 $H(s), B(s)$ 的极点分别只存在于 s 的左半平面和右半平面内。



如果 $S_x(s)$ 满足佩利-维纳条件，则有：

$$S_x(s) = S_x^+(s) S_x^-(s)$$

由于 $S_x(\omega) = S_x^*(\omega) = S_x(-\omega)$ ，则

$$S_x^+(-s) = S_x^-(s)$$

于是有

$$H(s) S_x^+(s) = \frac{S_{gx}(s)}{S_x^-(s)} + \frac{B(s)}{S_x^-(s)} = \left[\frac{S_{gx}(s)}{S_x^-(s)} \right]^+ + \left[\frac{S_{gx}(s)}{S_x^-(s)} \right]^- + \frac{B(s)}{S_x^-(s)}$$


故

$$H(s) = \frac{1}{S_x^+(s)} \left[\frac{S_{gx}(s)}{S_x^-(s)} \right]^+ = \frac{1}{S_x^+(s)} \left[\frac{S_{sx}(s) e^{\alpha s}}{S_x^-(s)} \right]^+$$



2. 预白化法

基本思想：先将输入信号进行预白化处理，然后让得到的白化信号通过其对应的维纳滤波器。



白化滤波器取为

$$H_W(s) = \frac{1}{S_x^+(s)}$$



对于白信号输入为 $z(t)$ ，有 $R_z(\tau) = \delta(\tau)$ ，其对应的维纳滤波器满足如下方程：

$$R_{gz}(\tau) = \int_0^{+\infty} h'(\lambda) R_z(\tau - \lambda) d\lambda = h'(\tau), \quad \tau \geq 0$$

有：

$$H'(s) = \int_0^{+\infty} h'(\tau) e^{-s\tau} d\tau = [S_{gz}(s)]^+ = [H_W(-s) S_{gx}(s)]^+ = \left[\frac{S_{gx}(s)}{S_x^-(s)} \right]^+$$

则：

$$H(s) = H_W(s) H'(s) = \frac{1}{S_x^+(s)} \left[\frac{S_{gx}(s)}{S_x^-(s)} \right]^+$$

最小均方误差为：

$$E\{e^2(t)\}_{\min} = E\{e(t)g(t)\} = R_s(0) - \int_0^{+\infty} h(\lambda) R_{gx}(\lambda) d\lambda$$



例 6.2

考虑输入信号 $x(t)$ 为高斯-马尔可夫信号 $s(t)$ 和噪声 $n(t)$ 的叠加，假定信号和噪声统计独立，其功率谱分别为 $S_s(\omega) = \frac{3}{1+\omega^2}$ 和 $S_n(\omega) = 1$ 。

求： α 分别取0，+1和-1时物理可实现维纳滤波器的冲激响应及最小均方误差。



6.2.4 最小均方误差

物理可实现维纳滤波器的最小均方误差可以表示为：


$$E\{e^2(t)\}_{\min} = R_s(0) - \int_{-\infty}^{+\infty} h(\tau) R_{sx}(\alpha + \tau) d\tau$$

可推得：

$$E\{e^2(t)\}_{\min} = R_s(0) - \int_{\alpha}^{+\infty} \phi^2(\tau) d\tau$$

其中 $\phi(\tau) = R_{sz}(\tau) = E\{s(t)z(t-\tau)\}$ 。

可见：最小均方误差随着 α 值的增大而单调地增大。



预测、滤波和平滑的性能示意图

结论：

平滑用到的数据最多，对应的阴影面积最大，其误差最小；而预测用到的数据最少，其对应的阴影面积最下，误差最大；滤波所用到的数据居中，其误差也位于前二者之间。



6.3 离散维纳滤波

对于随机输入序列 $x(k) = s(k) + n(k)$ ，待估计的信号序列为 $g(k) = s(k + \alpha)$ 。系统的输出为

$$y(k) = \sum_{j=-\infty}^{+\infty} h(k-j)x(j) = \sum_{j=-\infty}^{+\infty} h(j)x(k-j)$$

选取 $h(k)$ 使得 $y(k)$ 的估计均方误差

$$E\{e^2(k)\} = E\{[g(k) - y(k)]^2\}$$

达到最小，这时的离散线性系统称为随机序列的维纳滤波器。其解满足线性最小均方误差估计的正交条件：

$$E\left\{\left[g(k) - \sum_{j=-\infty}^{+\infty} h(j)x(k-j)\right]x(j')\right\} \equiv 0$$



有限观测样本的维纳滤波

每次对于 $g(k)$ 的估计，只使用长度为 N 的观测样本，即

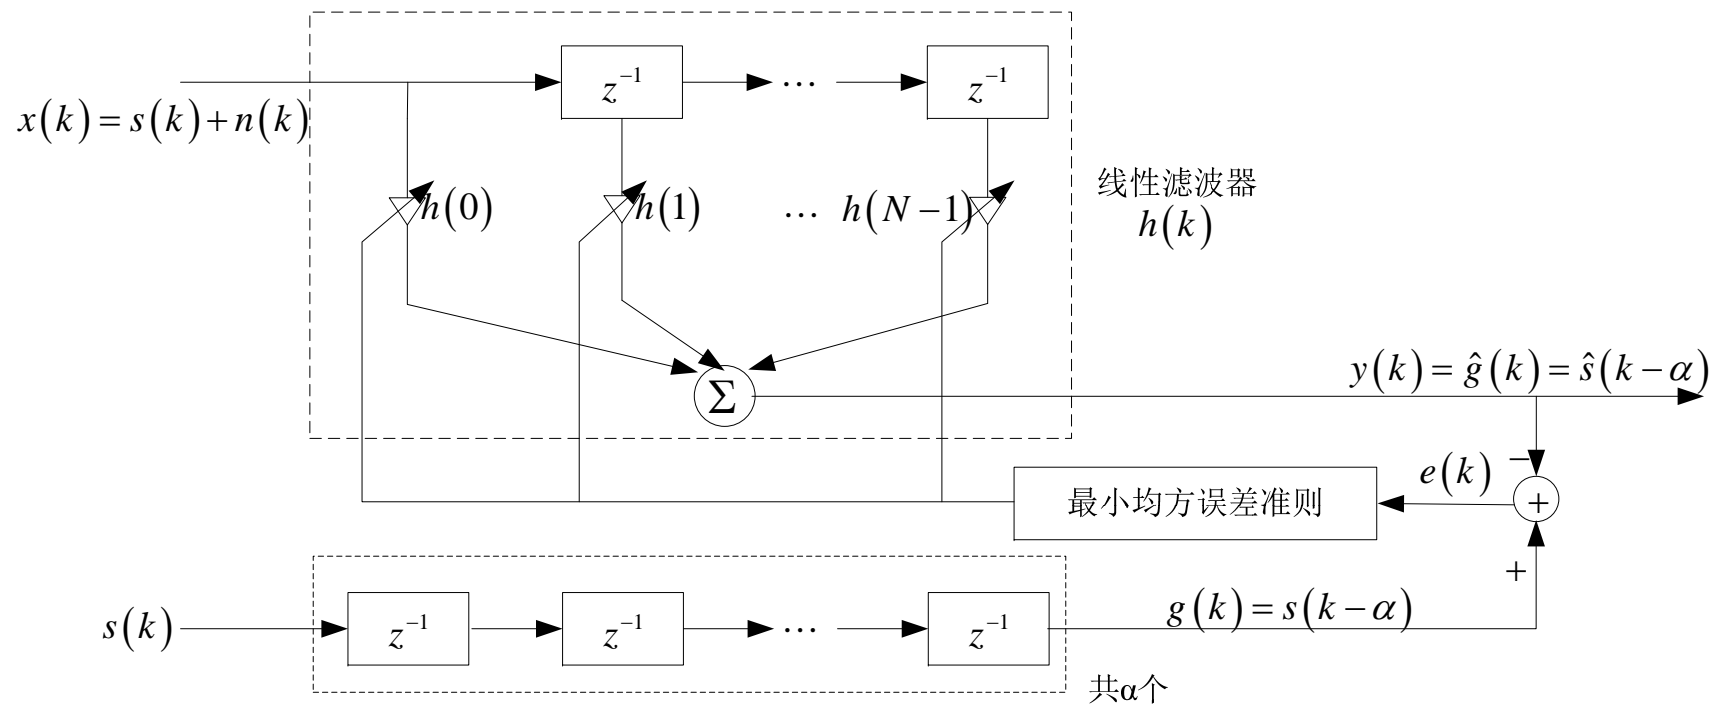
$$y(k) = \sum_{j=0}^{N-1} h(j) x(k-j)$$

则维纳滤波方程如下：

$$\sum_{i=0}^{N-1} h(i) R_x(l-i) = R_{gx}(l) \quad l = 0, 1, \dots, N-1$$

矢量形式为： $\mathbf{R}_x \mathbf{h} = \mathbf{r}_{gx}$ ， 则： $\mathbf{h} = \mathbf{R}_x^{-1} \mathbf{r}_{gx}$

均方误差为： $E\{e^2(k)\}_{\min} = R_g(0) - \sum_{j=0}^{N-1} h(j) R_{gx}(j)$





6.4 $\alpha - \beta$ 滤波

下面通过举例引入 $\alpha - \beta$ 滤波。

假设常值信号中混杂了加性噪声，现用 N 个观测样本

$x_k = s + n_k$ 来估计常值信号 s 。

一种处理方法是：

1. 测量 x_1 ，存储 x_1 ，取样本均值估计量为 $\hat{s}_1 = x_1$ ；
2. 测量 x_2 ，存储 x_2 ，取样本均值估计量为 $\hat{s}_2 = \frac{1}{2}(x_1 + x_2)$ ；
3. 依此类推，测量 x_N ，存储 x_N ，取样本均值估计量为

$$\hat{s}_N = \frac{1}{N}(x_1 + x_2 + \cdots + x_N)。$$



另一种处理方法是：

1. 测量 x_1 ，取样本均值估计量为 $\hat{s}_1 = x_1$ ，存储 \hat{s}_1 ，清除 x_1 ；
2. 测量 x_2 ，取样本均值估计量为 $\hat{s}_2 = \frac{1}{2}(x_2 + \hat{s}_1)$ ，存储 \hat{s}_2 ，清除 x_2, \hat{s}_1 ；
3. 依此类推，测量 x_N ，取样本均值估计量为 $\hat{s}_N = \frac{N-1}{N}\hat{s}_{N-1} + \frac{1}{N}x_N$ ，存储 \hat{s}_N ，清除 \hat{s}_{N-1}, x_N 。



例：

需要对一运动目标进行跟踪测量，估计出目标的位移与速度。假设目标在时刻 t_k 的位移为 x_k ，采样间隔 T ，并且假设在时间区间 $[t_k, t_k + T]$ 内目标作匀速直线运动。观测样本为 $y_k = x_k + n_k$

做法：用 \hat{x}_k 表示对目标位移 x_k 的估计值，则 $\hat{\dot{x}}_k$ 为该时刻目标的速度估计值。

建立预测方程：

$$\begin{aligned}\hat{x}_{k+1}^- &= \hat{x}_k + T\hat{\dot{x}}_k \\ \hat{\dot{x}}_{k+1}^- &= \hat{\dot{x}}_k\end{aligned}$$



利用新的观测值 y_{k+1} 建立更新方程：

$$\hat{x}_{k+1} = \hat{x}_{k+1}^- + \alpha (y_{k+1} - \hat{x}_{k+1}^-)$$

$$\hat{\dot{x}}_{k+1} = \hat{\dot{x}}_{k+1}^- + \frac{\beta}{T} (y_{k+1} - \hat{x}_{k+1}^-)$$

矢量形式：

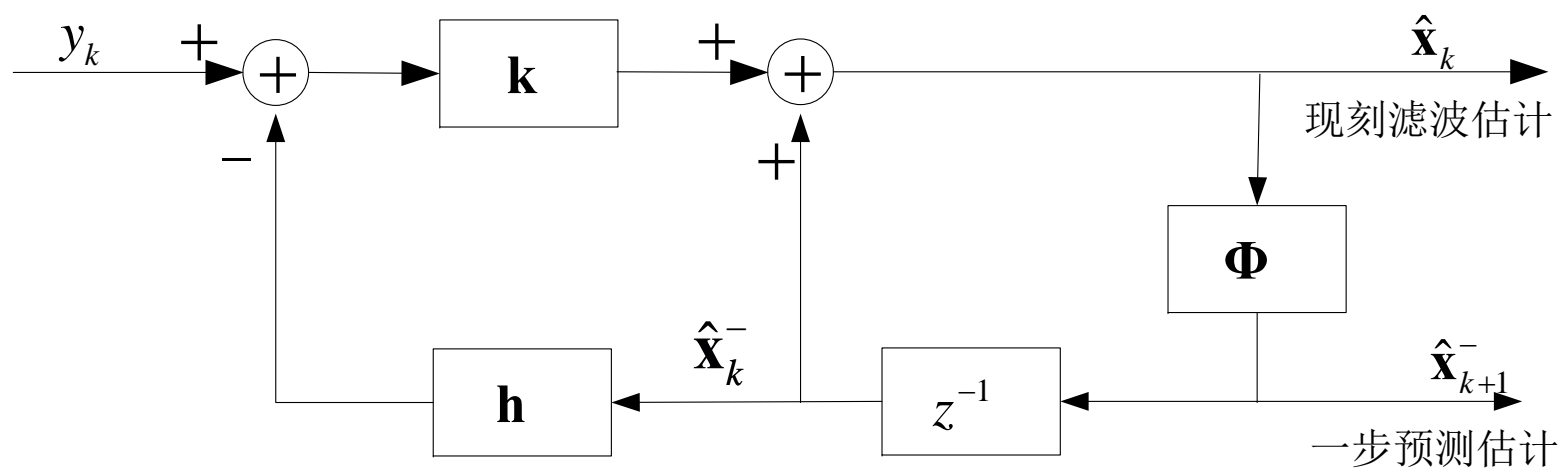
$$\hat{\mathbf{x}}_{k+1} = \mathbf{\Phi} \hat{\mathbf{x}}_k + \mathbf{k} (y_{k+1} - \mathbf{h} \mathbf{\Phi} \hat{\mathbf{x}}_k) \quad \hat{\mathbf{x}}_k = [\hat{x}_k, \hat{\dot{x}}_k]^T$$

$$\mathbf{\Phi} = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}, \mathbf{k} = [\alpha \quad \beta/T]^T, \mathbf{h} = [1 \quad 0]$$

上述递推算法称为 $\alpha - \beta$ 滤波。



递推运算流程





6.5 卡尔曼滤波

主要内容：

6.5.1 状态空间模型

6.5.2 离散卡尔曼滤波



6.5.1 状态空间模型

1. 状态变量、状态方程和观测方程


状态变量：描述系统状态的一组数目最少的变量

状态方程：状态变量所满足的一阶微分方程

观测方程：描述系统输出与状态变量之间关系的方程



例：RLC电路



由基尔霍夫定律：

$$u_i(t) = (R + r) \cdot i(t) + L \frac{di(t)}{dt} + \frac{1}{C} \int_{-\infty}^t i(\tau) d\tau$$
$$u_o(t) = R \cdot i(t)$$



利用

$$i(t) = \frac{dq(t)}{dt}, \quad q(t) = \int_{-\infty}^t i(\tau) d\tau$$

可得

$$L \frac{d^2 q(t)}{dt^2} + (R + r) \frac{dq(t)}{dt} + \frac{1}{C} q(t) = u_i(t)$$

$$u_o(t) = R \frac{dq(t)}{dt}$$

令

$$q(t) = x_1(t), \quad \frac{dq(t)}{dt} = x_2(t), \quad y(t) = u_o(t)$$

可得

$$\begin{cases} \dot{x}_1(t) = x_2(t) \\ \dot{x}_2(t) = -\frac{1}{LC} x_1(t) - \frac{R+r}{L} x_2(t) + \frac{u(t)}{L} \\ y(t) = R x_2(t) \end{cases}$$



写出矢量形式

$$\begin{cases} \begin{bmatrix} \dot{x}_1(t) \\ \dot{x}_2(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -1/LC & -(R+r)/L \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} + \begin{bmatrix} 0 \\ 1/L \end{bmatrix} u(t) \\ y(t) = \begin{bmatrix} 0 & R \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} \end{cases}$$

一般的矢量形式

$$\dot{\mathbf{x}}(t) = \mathbf{F}(t)\mathbf{x}(t) + \mathbf{G}(t)\mathbf{u}(t) \quad \leftarrow \text{状态方程}$$

$$\mathbf{y}(t) = \mathbf{H}(t)\mathbf{x}(t) + \mathbf{n}(t) \quad \leftarrow \text{观测方程}$$

如何用状态空间模型来描述随机过程？



2. 状态方程的解

状态方程是一个一阶P元联立的线性微分方程组，其

齐次方程组： $\dot{\mathbf{x}}(t) = \mathbf{F}(t)\mathbf{x}(t)$

有P个线性独立的解 $\mathbf{x}^1(t), \mathbf{x}^2(t), \dots, \mathbf{x}^p(t)$

这组解构成的非奇异矩阵，称为上式的基本解阵

$$\mathbf{X}(t) = [\mathbf{x}^1(t), \mathbf{x}^2(t), \dots, \mathbf{x}^p(t)]$$

满足微分方程

$$\frac{d\mathbf{X}(t)}{dt} = \mathbf{F}(t)\mathbf{X}(t)$$



定义：对于 $t, \tau \geq t_0$ ，矩阵 $\Phi(t, \tau) = \mathbf{X}(t)\mathbf{X}^{-1}(\tau)$ 为系统的状态转移矩阵。

状态转移矩阵具有以下性质：

a. 对于 $\tau \geq t_0$
$$\frac{\partial \Phi(t, \tau)}{\partial t} = \mathbf{F}(t)\Phi(t, \tau)$$

b. 对于 $t \geq t_0$
$$\Phi(t, t) = \mathbf{I}$$

c. 对于 $t, \tau \geq t_0$
$$\Phi^{-1}(t, \tau) = \mathbf{X}(\tau)\mathbf{X}^{-1}(t) = \Phi(\tau, t)$$

d. 对于 $t_1, t_2, t_3 \geq t_0$
$$\Phi(t_3, t_2)\Phi(t_2, t_1) = \Phi(t_3, t_1)$$

e. 对于 $t, \tau \geq t_0$
$$\frac{\partial \Phi(t, \tau)}{\partial \tau} = -\Phi(t, \tau)\mathbf{F}(\tau)$$



对于因果系统，状态方程的唯一解可由状态转移矩阵表示为：

$$\mathbf{x}(t) = \mathbf{\Phi}(t, t_0)\mathbf{x}(t_0) + \int_{t_0}^t \mathbf{\Phi}(t, \tau)\mathbf{G}(\tau)\mathbf{u}(\tau)d\tau$$

验证初始值：

$$\mathbf{x}(t_0) = \mathbf{\Phi}(t_0, t_0)\mathbf{x}(t_0) + \int_{t_0}^{t_0} \mathbf{\Phi}(t_0, \tau)\mathbf{G}(\tau)\mathbf{u}(\tau)d\tau = \mathbf{x}_0$$

两侧对 t 求导：

$$\begin{aligned}\dot{\mathbf{x}}(t) &= \frac{\partial \mathbf{\Phi}(t, t_0)}{\partial t} \mathbf{x}_0 + \mathbf{\Phi}(t, \tau)\mathbf{G}(\tau)\mathbf{u}(\tau) \Big|_{\tau=t} + \int_{t_0}^t \frac{\partial \mathbf{\Phi}(t, \tau)}{\partial t} \mathbf{G}(\tau)\mathbf{u}(\tau)d\tau \\ &= \mathbf{F}(t)\mathbf{\Phi}(t, t_0)\mathbf{x}_0 + \mathbf{G}(t)\mathbf{u}(t) + \mathbf{F}(t) \int_{t_0}^t \mathbf{\Phi}(t, \tau)\mathbf{G}(\tau)\mathbf{u}(\tau)d\tau \\ &= \mathbf{F}(t)\mathbf{x}(t) + \mathbf{G}(t)\mathbf{u}(t)\end{aligned}$$



$$\mathbf{x}(t) = \Phi(t, 0)\mathbf{x}(0) + \int_0^t \Phi(t, \tau)\mathbf{G}(\tau)\mathbf{u}(\tau)d\tau$$



“零输入”解



“零状态”解

对于线性非时变系统，相关矩阵退化为常数矩阵：

$$\dot{\mathbf{x}}(t) = \mathbf{F}\mathbf{x}(t) + \mathbf{G}\mathbf{u}(t) \quad t \geq t_0$$

$$\mathbf{y}(t) = \mathbf{H}\mathbf{x}(t) + \mathbf{n}(t) \quad t \geq t_0$$

可以证明此时的解为：

$$\mathbf{x}(t) = \Phi(t - t_0)\mathbf{x}(t_0) + \int_{t_0}^t \Phi(t - \tau)\mathbf{G}\mathbf{u}(\tau)d\tau$$

$$\Phi(t, \tau) = \Phi(t - \tau) = e^{\mathbf{F}(t - \tau)} = \sum_{k=0}^{+\infty} \frac{\mathbf{F}^k (t - \tau)^k}{k!}$$



3. 离散状态方程和观测方程

对状态方程的时域解采样：

$$\mathbf{x}(t_{k+1}) = \mathbf{\Phi}(t_{k+1} - t_k) \mathbf{x}(t_k) + \int_{t_k}^{t_{k+1}} \mathbf{\Phi}(t_{k+1} - \tau) \mathbf{G} \mathbf{u}(\tau) d\tau$$

可得：

$$\mathbf{x}_{k+1} = \mathbf{\Phi}_{k+1,k} \mathbf{x}_k + \mathbf{u}_k$$

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{n}_k$$



6.5.2 离散卡尔曼滤波

一. 标量信号的卡尔曼滤波

状态方程: $x_k = ax_{k-1} + u_{k-1}$

观测方程: $y_k = x_k + n_k$

其中 $E\{u_k\} = E\{n_k\} = E\{u_k n_j\} = 0$

$$E\{u_k u_j\} = \sigma_u^2 \delta_{kj}, E\{n_k n_j\} = \sigma_n^2 \delta_{kj}$$

$$E\{x_k\} = 0, E\{x_k^2\} = \sigma_x^2$$

利用最小均方误差估计准则, 分别估计 $\hat{x}_k, \hat{x}_{k+1|k}$ 。



1. 递推滤波

如下定义线性递推滤波：

$$\hat{x}_k = a_k \hat{x}_{k-1} + b_k y_k$$

利用最小均方误差估计准则： $\xi_k = E\{(x_k - \hat{x}_k)^2\} \rightarrow \min$

$$\begin{cases} \frac{\partial \xi_k}{\partial a_k} = -2E\{(x_k - a_k \hat{x}_{k-1} - b_k y_k) \hat{x}_{k-1}\} = 0 \\ \frac{\partial \xi_k}{\partial b_k} = -2E\{(x_k - a_k \hat{x}_{k-1} - b_k y_k) y_k\} = 0 \end{cases}$$

即：

$$\begin{cases} E\{(x_k - \hat{x}_k) \hat{x}_{k-1}\} = 0 & (1) \\ E\{(x_k - \hat{x}_k) y_k\} = 0 & (2) \end{cases} \quad \text{正交条件}$$



则： $\xi_k = E\{(x_k - \hat{x}_k)^2\} = E\{(x_k - \hat{x}_k)x_k\}$ (3)

由 (1) 可得： $a_k = a(1 - b_k)$

此时：

$$\begin{aligned}\hat{x}_k &= a\hat{x}_{k-1} + b_k(y_k - a\hat{x}_{k-1}) \\ &= \hat{x}_{k|k-1} + b_k(y_k - \hat{x}_{k|k-1})\end{aligned}$$

由 (2) 可得：

$$b_k = \frac{\xi_k}{\sigma_n^2} = \frac{A + a^2 b_{k-1}}{1 + A + a^2 b_{k-1}}, \quad A = \frac{\sigma_u^2}{\sigma_n^2} \quad \longrightarrow \quad \begin{array}{l} \text{归一化估计} \\ \text{均方误差} \end{array}$$



由 (3) 可得:

$$\begin{aligned}\xi_k &= E\{(x_k - \hat{x}_k)x_k\} = E\{x_k^2 - \hat{x}_k x_k\} \\&= E\{a^2 x_{k-1}^2\} + \sigma_u^2 - E\{(a_k \hat{x}_{k-1} + b_k y_k)(ax_{k-1} + u_{k-1})\} \\&= a^2 E\{x_{k-1}^2\} + \sigma_u^2 - a_k a E\{x_{k-1} \hat{x}_{k-1}\} - ab_k E\{y_k x_{k-1}\} - b_k E\{y_k u_{k-1}\} \\&= a^2 E\{x_{k-1}^2\} + \sigma_u^2 - a_k a E\{x_{k-1} \hat{x}_{k-1}\} - ab_k E\{(ax_{k-1} + u_{k-1} + n_k)x_{k-1}\} - b_k \sigma_u^2 \\&= a^2 E\{x_{k-1}^2\} + \sigma_u^2 - a^2 (1 - b_k) E\{x_{k-1} \hat{x}_{k-1}\} - a^2 b_k E\{x_{k-1}^2\} - b_k \sigma_u^2 \\&= a^2 \left[E\{x_{k-1}^2\} - E\{x_{k-1} \hat{x}_{k-1}\} \right] + \sigma_u^2 - a^2 b_k \left[E\{x_{k-1}^2\} - E\{x_{k-1} \hat{x}_{k-1}\} \right] - b_k \sigma_u^2 \\&= a^2 \xi_{k-1} + \sigma_u^2 - a^2 b_k \xi_{k-1} - b_k \sigma_u^2\end{aligned}$$

初始条件:

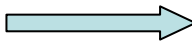
$$\begin{cases} \hat{x}_0 = E\{x_0\} \\ e_0 = Var\{x_0\} \end{cases}$$



当动态噪声很小，即 $\sigma_u^2 = 0$ ，且 $a = 1$ ，则：

$$x_k = x_{k-1} = x$$

$$A = \frac{\sigma_u^2}{\sigma_n^2} = 0$$

此时： $b_k = \frac{b_{k-1}}{1 + b_{k-1}} = \frac{\xi_{k-1}}{\sigma_n^2 + \xi_{k-1}}$  参量递推估计

当观测噪声很小，即 $\sigma_n^2 = 0$ ，则： $b_k \approx 1, a_k \approx 0$

此时： $\hat{x}_k \approx y_k$



2. 递推预测

如下定义线性递推一步预测：

$$\hat{x}_{k+1|k} = \alpha_k \hat{x}_{k|k-1} + \beta_k y_k$$

利用最小均方误差估计准则：

$$\xi_{k+1|k} = E \left\{ (x_{k+1} - \hat{x}_{k+1|k})^2 \right\} \rightarrow \min$$

得正交条件：

$$\left\{ E \left\{ (x_{k+1} - \hat{x}_{k+1|k}) \hat{x}_{k|k-1} \right\} = 0 \right. \quad (1)$$

$$\left\{ E \left\{ (x_{k+1} - \hat{x}_{k+1|k}) y_k \right\} = 0 \right. \quad (2)$$



则：
$$\xi_{k+1|k} = E\{(x_{k+1} - \hat{x}_{k+1|k})x_{k+1}\} = \sigma_x^2 - E\{\hat{x}_{k+1|k}x_{k+1}\} \quad (3)$$

由（1）可得：
$$\alpha_k = a - \beta_k$$

此时：
$$\hat{x}_{k+1|k} = a\hat{x}_{k|k-1} + \beta_k(y_k - \hat{x}_{k|k-1})$$

由（2）：
$$\begin{aligned} E\{(ax_k + u_k - \hat{x}_{k+1|k})y_k\} &= a\sigma_x^2 - E\{(\alpha_k \hat{x}_{k|k-1} + \beta_k y_k)y_k\} \\ &= a\sigma_x^2 - \alpha_k(\sigma_x^2 - \xi_{k|k-1}) - \beta_k(\sigma_x^2 + \sigma_n^2) \\ &= a\sigma_x^2 - (a - \beta_k)(\sigma_x^2 - \xi_{k|k-1}) - \beta_k(\sigma_x^2 + \sigma_n^2) = 0 \end{aligned}$$

可得：

$$\beta_k = \frac{a\xi_{k|k-1}}{\xi_{k|k-1} + \sigma_n^2}$$



由于：

$$\begin{aligned} E\{\hat{x}_{k+1|k}x_{k+1}\} &= E\{(\alpha_k\hat{x}_{k|k-1} + \beta_k y_k)x_{k+1}\} \\ &= a\alpha_k(\sigma_x^2 - \xi_{k|k-1}) + \beta_k E\{(x_k + n_k)(ax_k + u_k)\} \\ &= a\alpha_k(\sigma_x^2 - \xi_{k|k-1}) + a\beta_k\sigma_x^2 \end{aligned}$$

又：

$$\begin{aligned} \sigma_u^2 &= E\{(x_k - ax_{k-1})^2\} = \sigma_x^2 + a^2\sigma_x^2 - 2aE\{x_k x_{k-1}\} \\ &= \sigma_x^2 + a^2\sigma_x^2 - 2aE\{(ax_{k-1} + u_{k-1})x_{k-1}\} \\ &= \sigma_x^2 + a^2\sigma_x^2 - 2a^2\sigma_x^2 = \sigma_x^2 - a^2\sigma_x^2 \end{aligned}$$

由 (3) 可得：

$$\begin{aligned} \xi_{k+1|k} &= \sigma_x^2 - a\alpha_k(\sigma_x^2 - \xi_{k|k-1}) - a\beta_k\sigma_x^2 \\ &= \sigma_x^2 - a(\alpha_k + \beta_k)\sigma_x^2 + a\alpha_k\xi_{k|k-1} \\ &= a(a - \beta_k)\xi_{k|k-1} - a^2\sigma_x^2 + \sigma_x^2 \\ &= a^2\xi_{k|k-1} - a\beta_k\xi_{k|k-1} + \sigma_u^2 \end{aligned}$$



3. 滤波与预测的关系

由：
$$x_{k+1} = ax_k + u_k$$

得：
$$\hat{x}_{k+1|k} = a\hat{x}_k$$

代入递推滤波：
$$\begin{aligned}\hat{x}_k &= a\hat{x}_{k-1} + b_k(y_k - a\hat{x}_{k-1}) \\ &= \hat{x}_{k|k-1} + b_k(y_k - \hat{x}_{k|k-1})\end{aligned}$$

则：
$$a\hat{x}_k = a\hat{x}_{k|k-1} + ab_k(y_k - \hat{x}_{k|k-1})$$

比较递推预测得：
$$\beta_k = ab_k$$

此外：
$$\xi_{k+1|k} = E\{(x_{k+1} - \hat{x}_{k+1|k})^2\} = E\{(ax_k + u_k - \hat{x}_{k+1|k})^2\} = a^2\xi_k + \sigma_u^2$$



二. 矢量信号的卡尔曼滤波

状态方程: $\mathbf{x}_{k+1} = \Phi_{k+1,k} \mathbf{x}_k + \mathbf{u}_k$

观测方程: $\mathbf{y}_{k+1} = \mathbf{H}_{k+1} \mathbf{x}_{k+1} + \mathbf{n}_{k+1}$

假设在时刻 t_k ，基于该时刻以前所获得的全部知识，对状态变量 \mathbf{x}_k 做一个预测估计 $\hat{\mathbf{x}}_k^- (\hat{\mathbf{x}}_{k|k-1})$ 。预测估计的误差为：

$$\mathbf{e}_k^- = \mathbf{x}_k - \hat{\mathbf{x}}_k^-$$

预测误差的协方差矩阵为：

$$\mathbf{C}_k^- = E\{\mathbf{e}_k^- \mathbf{e}_k^{-T}\} = E\left\{\left(\mathbf{x}_k - \hat{\mathbf{x}}_k^-\right)\left(\mathbf{x}_k - \hat{\mathbf{x}}_k^-\right)^T\right\}$$



利用 t_k 时刻的新观测数据 \mathbf{y}_k 进一步改善对 \mathbf{x}_k 的估计 $\hat{\mathbf{x}}_k$ ，称为更新估计。

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (\mathbf{y}_k - \mathbf{H}_k \hat{\mathbf{x}}_k^-)$$

更新估计的误差为：

$$\mathbf{e}_k = \mathbf{x}_k - \hat{\mathbf{x}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{e}_k^- - \mathbf{K}_k \mathbf{n}_k$$

更新估计的均方误差为：

$$E\{\mathbf{e}_k^T \mathbf{e}_k\} = E\{(\mathbf{x}_k - \hat{\mathbf{x}}_k)^T (\mathbf{x}_k - \hat{\mathbf{x}}_k)\} \xrightarrow{\mathbf{K}_k} \min$$

更新误差的协方差矩阵为：

$$\begin{aligned} \mathbf{C}_k &= E\{\mathbf{e}_k \mathbf{e}_k^T\} = E\{(\mathbf{x}_k - \hat{\mathbf{x}}_k)(\mathbf{x}_k - \hat{\mathbf{x}}_k)^T\} \\ &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{C}_k^- (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T \end{aligned}$$

其中：

$$E\{\mathbf{n}_k \mathbf{n}_i^T\} = \mathbf{R}_k \delta_{ik}$$



令 $\mathbf{D}_k \mathbf{D}_k^T = \mathbf{H}_k \mathbf{C}_k^- \mathbf{H}_k^T + \mathbf{R}_k$

可得 $\mathbf{C}_k = \mathbf{C}_k^- + (\mathbf{K}_k \mathbf{D}_k - \mathbf{A})(\mathbf{K}_k \mathbf{D}_k - \mathbf{A})^T - \mathbf{A} \mathbf{A}^T$

$$\mathbf{A} = \mathbf{C}_k^- \mathbf{H}_k^T (\mathbf{D}_k^T)^{-1}$$

当 $\mathbf{K}_k \mathbf{D}_k - \mathbf{A} = \mathbf{0}$

此时 \mathbf{C}_k 的主对角线元素之和达到最小

$$\text{即 } \mathbf{K}_k = \mathbf{A} \mathbf{D}_k^{-1} = \mathbf{C}_k^- \mathbf{H}_k^T (\mathbf{D}_k^T)^{-1} \mathbf{D}_k^{-1} = \mathbf{C}_k^- \mathbf{H}_k^T (\mathbf{H}_k \mathbf{C}_k^- \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

此时 $\mathbf{C}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{C}_k^-$



下面利用 $\hat{\mathbf{x}}_k, \mathbf{C}_k$ 预测估计 $\hat{\mathbf{x}}_{k+1}^-, \mathbf{C}_{k+1}^-$ 。

由状态方程 $\mathbf{x}_{k+1} = \Phi_{k+1,k} \mathbf{x}_k + \mathbf{u}_k$

可得 $\hat{\mathbf{x}}_{k+1}^- = \Phi_{k+1,k} \hat{\mathbf{x}}_k$

则 t_{k+1} 时刻的预测误差和协方差矩阵分别为

$$\mathbf{e}_{k+1}^- = \mathbf{x}_{k+1} - \hat{\mathbf{x}}_{k+1}^- = \Phi_{k+1,k} \mathbf{e}_k + \mathbf{u}_k$$

$$\mathbf{C}_{k+1}^- = E\left\{\mathbf{e}_{k+1}^- \mathbf{e}_{k+1}^{-T}\right\} = \Phi_{k+1,k} \mathbf{C}_k \Phi_{k+1,k}^T + \mathbf{Q}_k$$

其中 $E\left\{\mathbf{u}_k \mathbf{u}_i^T\right\} = \mathbf{Q}_k \delta_{ik}$



卡尔曼滤波算法的递推过程

(1) 设置初始化条件: $\hat{\mathbf{x}}_0 = E\{\mathbf{x}_0\}, \quad \mathbf{C}_0 = Var\{\mathbf{x}_0\}$

(2) 预测: $\hat{\mathbf{x}}_{k+1}^- = \Phi_{k+1,k} \hat{\mathbf{x}}_k$

(3) 计算预测误差协方差矩阵: $\mathbf{C}_{k+1}^- = \Phi_{k+1,k} \mathbf{C}_k \Phi_{k+1,k}^T + \mathbf{Q}_k$

(4) 计算卡尔曼增益: $\mathbf{K}_{k+1} = \mathbf{C}_{k+1}^- \mathbf{H}_{k+1}^T \left(\mathbf{H}_{k+1} \mathbf{C}_{k+1}^- \mathbf{H}_{k+1}^T + \mathbf{R}_{k+1} \right)^{-1}$

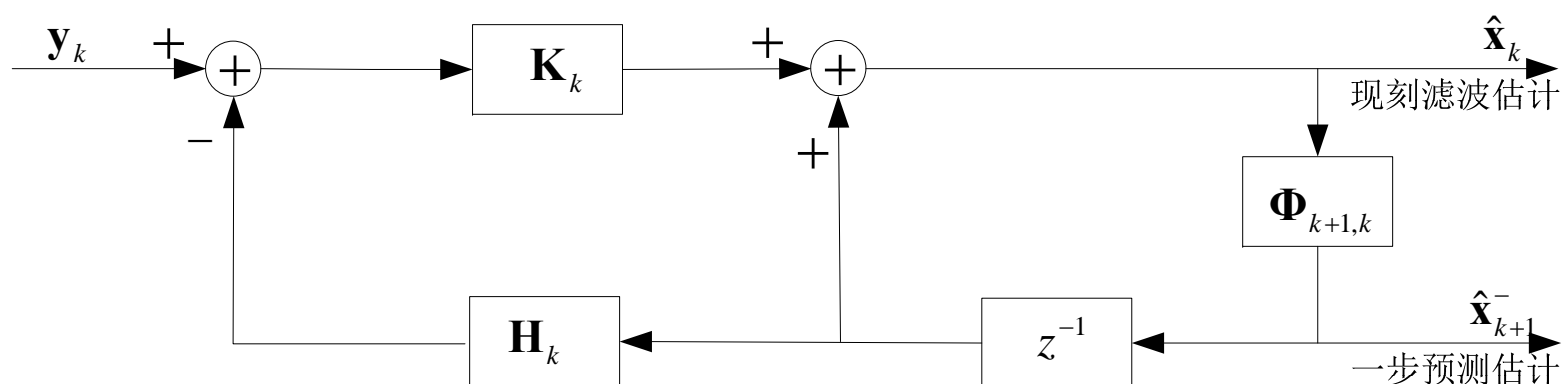
(5) 更新: $\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_{k+1}^- + \mathbf{K}_{k+1} \left(\mathbf{y}_{k+1} - \mathbf{H}_{k+1} \hat{\mathbf{x}}_{k+1}^- \right)$



(6) 计算更新误差协方差矩阵: $\mathbf{C}_{k+1} = (\mathbf{I} - \mathbf{K}_{k+1} \mathbf{H}_{k+1}) \mathbf{C}_{k+1}^-$

(7) 令 $k = k + 1$, 重复步骤 (2) - (6) 直到当前时刻。

迭代框图:





例6.3：飞机相对于雷达作径向直线匀加速运动。目标与雷达站之间的斜距为 x_k 。目标相对于雷达的距离方程、速度方程和加速度方程为

$$x_k = x_{k-1} + T\dot{x}_{k-1} + \frac{T^2}{2}\ddot{x}_{k-1}, \quad \dot{x}_k = \dot{x}_{k-1} + T\ddot{x}_{k-1}, \quad \ddot{x}_k = \ddot{x}_{k-1}$$

式中， x_k 为 k 时刻目标的斜距， \dot{x}_k 为 k 时刻目标的径向速度， \ddot{x}_k 为 k 时刻目标的径向加速度， T 为采样时间间隔， $T = 2s$ 。



已知

$$E\{x_0\} = 0, \quad \text{Var}\{x_0\} = 8(km)^2$$
$$E\{\dot{x}_0\} = 0, \quad \text{Var}\{\dot{x}_0\} = 10(km/s)^2$$
$$E\{\ddot{x}_0\} = 0.2, \quad \text{Var}\{\ddot{x}_0\} = 5(km/s)^2$$

且目标未受外界干扰，动态噪声 $u_k = 0$, n_k 是零均值的白噪声，即 $E\{n_k\} = 0$, $\text{Cov}\{n_i, n_j\} = 0.15\delta_{ij}(km)^2$

n_k 与 $x_k, \dot{x}_k, \ddot{x}_k$ 都不相关。当观测时刻 $k = 1, 2, \dots, 10$ 时，斜距的观测值 $y_k(km)$ 为：

0.30, 1.56, 3.64, 6.44, 10.5, 14.8, 20.0, 25.2, 32.2, 40.4

求： $x_k, \dot{x}_k, \ddot{x}_k$ 的估计以及估计误差的协方差矩阵。